Deskriptive Statistik

Folgende Begriffe und Zusammenhänge sind hier noch einmal zusammengestellt und Voraussetzung für dieses Semester:

- Diskrete und stetige Merkmale
- Verteilung und Verteilungsfunktion bei diskreten und stetigen Merkmalen
- Arithmetisches Mittel und Varianz
- p-Quantile

Typisierung von Merkmalen

Diskrete Merkmale

Ein Merkmal heißt diskret, falls es nur abzählbar endlich viele oder abzählbar unendlich viele Realisierungen annehmen kann.
Diskret sind alle Merkmale, die man durch einfaches Abzählen 1,2,3,4, ... usw. erhalten kann; man ordnet jeder Realisierung eine natürliche Zahl zu. Die natürlichen Zahlen sind unendlich groß.
Benötigt man verbale Ausdrücke, um die Realisierungen anzugeben, handelt es sich ebenfalls um diskrete Merkmale.

Beispiele:
- Farben wie rot, blau, gelb usw. - verbale Ausdrücke
- Versuche bis zum Lösen einer Aufgabe (abzählbar unendlich)

Stetige Merkmale (kontinuierliche Merkmale)

Ein Merkmal heißt stetig, falls es (theoretisch) alle reellen Zahlen in einem Intervall als Realisierung annehmen kann. Dies bedeutet, es gibt überabzählbar unendlich viele Realisierungen.
Zu den stetigen Merkmalen gehören alle Merkmale, die in Zeit-, Mengen- oder Längeneinheiten gemessen werden können.

Beispiele:
- Körpergröße (Genauigkeit bis auf mm, usw.),
- Alter eines Menschen

Verteilung eines diskreten Merkmals

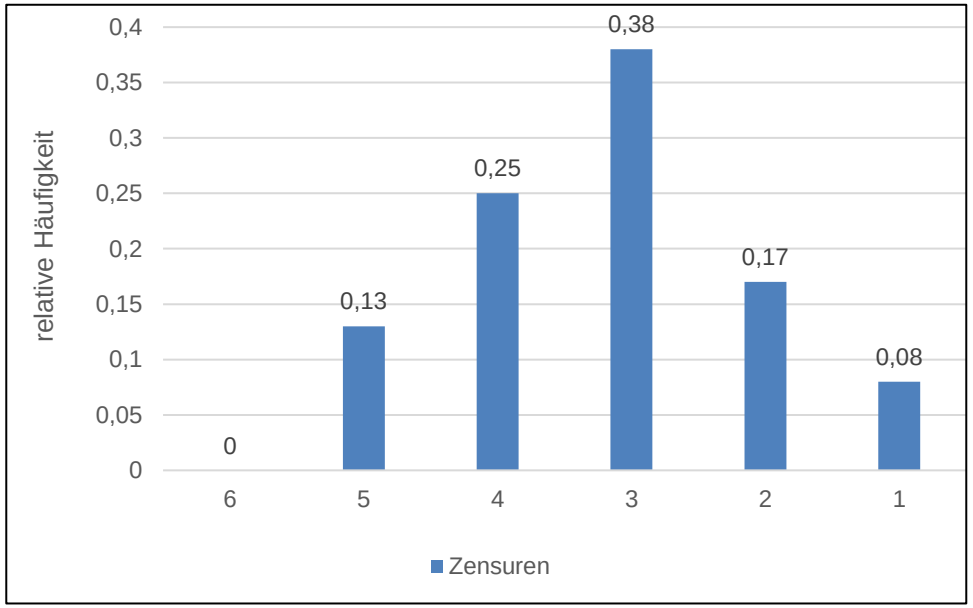
Eine Verteilung gibt an, welche Realisierungen das Merkmal annehmen kann und wie häufig jeder dieser Realisierungen auftritt. Diese Verteilung kann als Tabelle oder als Diagramm angegeben werden.

Beispiel:
Klausur einer Klasse mit 24 Schülern: Es gibt Zensuren von 6 bis 1. Für die Zensuren sind sowohl die absolute als auch die relative Häufigkeit angegeben.
In der Tabelle steht die Verteilung der Realisierungen:

Tabellarische Häufigkeitsverteilung

Zensur x_i	Absolute Häufigkeit $h(x_i)$	Relative Häufigkeit $f(x_i)$
6	0	0,0
5	3	0,13
4	6	0,25
3	9	0,38
2	4	0,17
1	2	0,08
Summe	**24**	**1**

Grafische Darstellung der relativen Häufigkeitsverteilung der Zensuren



Absolute und relative Summenhäufigkeit eines diskreten Merkmals

Zensuren x_i	Absolute Häufigkeit $h(x_i)$	Relative Häufigkeit $f(x_i)$	Absolute Summenhäufigkeit $H(x_i)$	Relative Summenhäufigkeit $F(x_i)$
6	0	0,00	0	0,00
5	3	0,13	3	0,13
4	6	0,25	9	0,38
3	9	0,38	18	0,75
2	4	0,17	22	0,92
1	2	0,08	**24**	**1,00**
Summe	**24**	**1**		

Definition:

Werden $k \leq n$ Merkmalsausprägungen angenommen, so gilt für die absolute Summenhäufigkeit:

$$H(x_i) = \sum_{x_k \leq x_i} h(x_k) = \sum_{k=1}^{i} h(x_k) \quad , \qquad i = 1, \dots, n$$

Die relative Summenhäufigkeit lautet:

$$F(x_i) = \sum_{x_k \leq x_i} f(x_k) = \sum_{k=1}^{i} f(x_k) = \sum_{k=1}^{i} \frac{h(x_k)}{n}, \qquad i = 1, \dots, n$$

Verteilungsfunktion eines diskreten Merkmals

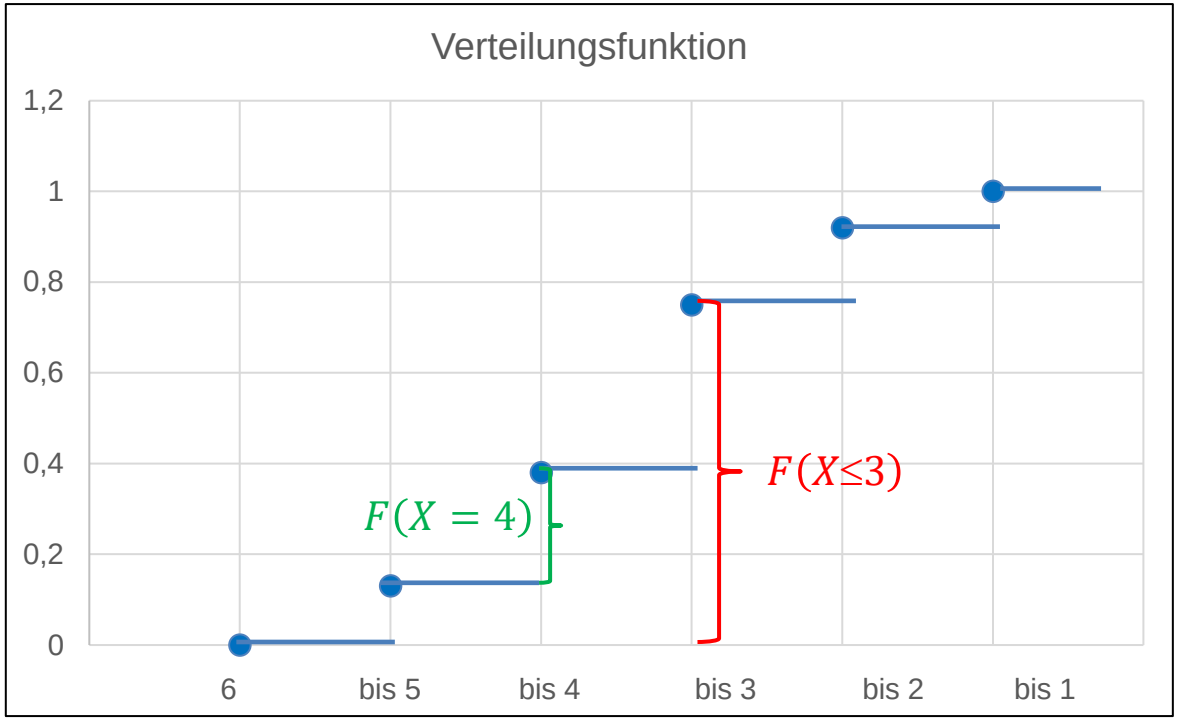
Eine Verteilungsfunktion ist eine mathematische Funktion. Sie gibt die kumulierte relative Summenhäufigkeit bis zu einer bestimmten Realisierung an. Sie wird als Funktion angegeben und kann grafisch dargestellt werden.

Zensuren x_i	Relative Summenhäufigkeit $F(x_i)$
6	0,00
5	0,13
4	0,38
3	0,75
2	0,92
1	**1,00**

Verteilungsfunktion:

$$F(x) = \begin{cases} 0 & , \quad x < 6 \\ 0 & , 6 \leq x < 5 \\ 0{,}13 & , 5 \leq x < 4 \\ 0{,}38 & , 4 \leq x < 3 \\ 0{,}75 & , 3 \leq x < 2 \\ 0{,}92 & , 2 \leq x < 1 \\ 1 & , \quad x \geq 1 \end{cases}$$

Grafische Darstellung - Treppenfunktion



6

Beispiel:

- $F(X\leq 3) = 0{,}75$ d.h. 75% der Schüler haben eine Note drei oder schlechter.
- $F(X=4) = 0{,}38 - 0{,}13 = 0{,}25$ d.h. der Anteil der Schüler, die genau die Note vier haben, liegt bei 0,25.

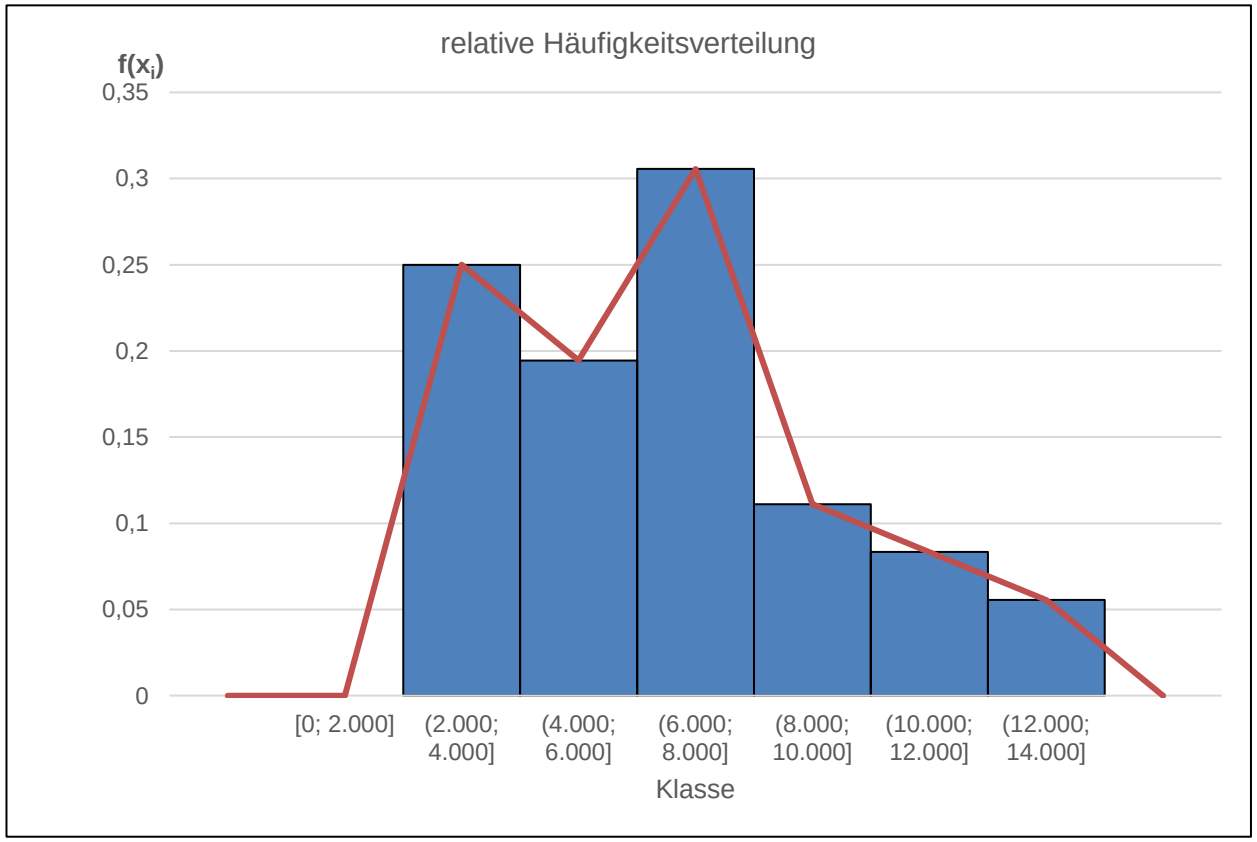
Verteilung eines stetigen Merkmals

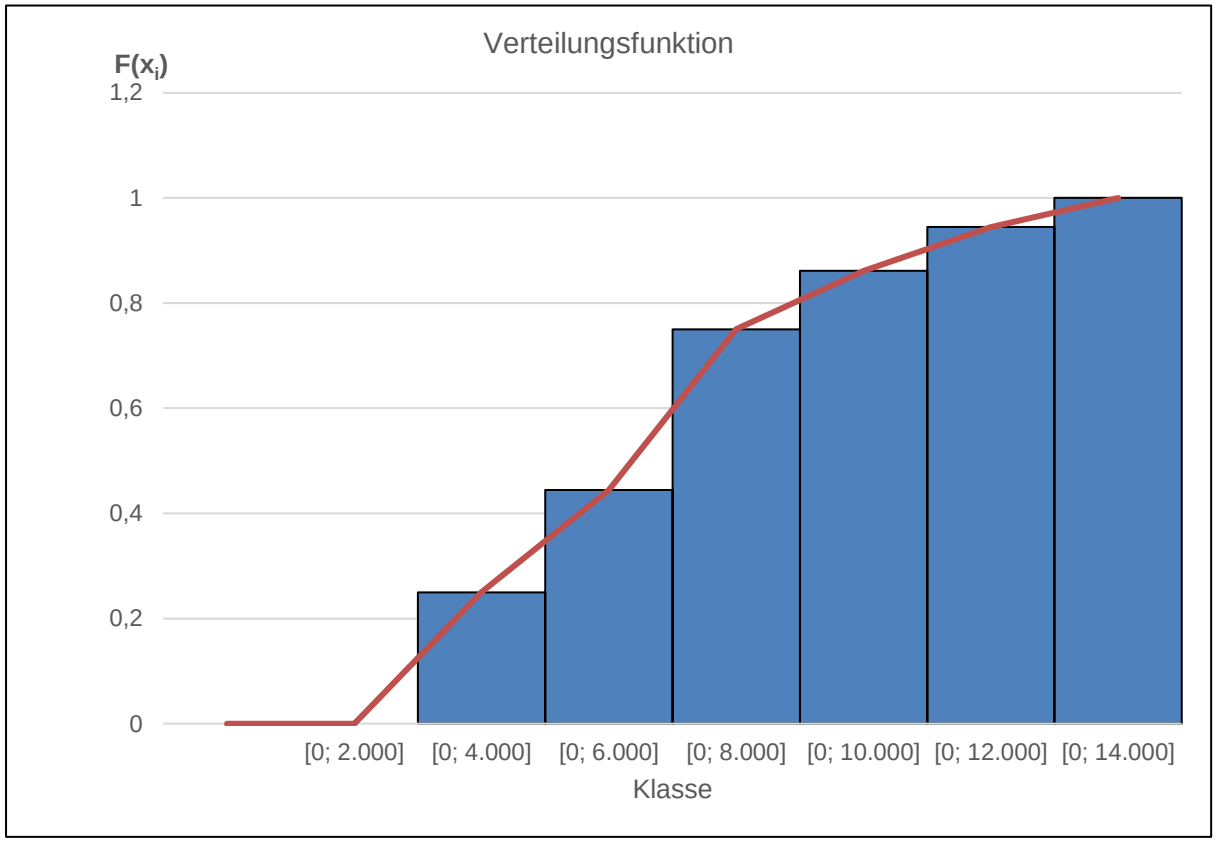
Beispiel: Wasserbezug der Letztverbraucher 2019 – Anzahl der Verwaltungsbezirke

Berechnung der absoluten und relativen Summenhäufigkeit

Wasserbezug in 1.000 m^3	absolute Häufigkeit	relative Häufigkeit	absolute Summenhäufigkeit	relative Summenhäufigkeit
	$\boldsymbol{h(x_i)}$	$\boldsymbol{f(x_i)}$	$\boldsymbol{H(x_i)}$	$\boldsymbol{F(x_i)}$
[0; 2.000]	0	0,000	0	0
(2.000; 4.000]	9	0,250	9	0,250
(4.000; 6.000]	7	0,194	16	0,444
(6.000; 8.000]	11	0,306	27	0,750
(8.000; 10.000]	4	0,111	31	0,861
(10.000; 12.000]	3	0,083	34	0,944
(12.000; 14.000]	2	0,056	36	1,000
Summe	**36**	**1**		

Grafische Darstellung der Verteilung und Verteilungsfunktion eines stetigen Merkmals





Histogramm

- Die Säulen liegen direkt nebeneinander.
- Statt eines Histogramms wird i.a. eine Kurvendarstellung (rote Linie) gewählt, da es innerhalb einer Klasse (Intervall) unendlich viele Ausprägungen gibt.
- Die Fläche einer Säule in der Verteilug ergibt die relative Häufigkeit in dem Intervall !

Arithmetisches Mittel und Varianz

Definition:
Seien $x_1, \dots, x_n$ Realisierungen einer Grundgesamtheit vom Umfang n. Das arithmetische Mittel lautet:

$$\bar{x} = \frac{1}{n} * \sum_{i=1}^{n} x_i$$

Das arithmetische Mittel ist die Summe aller Realisierungen dividiert durch die Anzahl der gesamten Realisierungen.

Liegt eine Häufigkeitsverteilung vor, berechnet sich das arithmetische Mittel wie folgt:

$$\bar{x} = \frac{1}{n} * \sum_{i=1}^{k} x_i * h(x_i) = \sum_{i=1}^{k} x_i * f(x_i), \qquad i = 1, \dots, k, \qquad k \leq n$$

Definition:
Die (empirische) Varianz ist das arithmetische Mittel der quadrierten Abweichungen metrisch skalierter Realisierungen von ihrem arithmetischen Mittel:

$$var(X) = s^2 = \frac{1}{n} * \sum_{i=1}^{n} (x_i - \bar{x})^2$$

Die Varianz ist das Maß für die Streuung einer Verteilung um ihren Mittelwert.

Es gilt:

$$var(X) = \frac{1}{n} * \sum_{i=1}^{n} (x_i - \bar{x})^2 = \frac{1}{n} * \sum_{i=1}^{n} x_i^2 - \bar{x}^2$$

Liegt eine Häufigkeitsverteilung der statistischen Reihe vor, so kann die Varianz auch damit berechnet werden:

$$s^2 = \frac{1}{n} * \sum_{i=1}^{k} (x_i - \bar{x})^2 * h(x_i) = \sum_{i=1}^{k} (x_i - \bar{x})^2 * f(x_i) \quad bzw. \quad s^2 = \frac{1}{n} * \sum_{i=1}^{k} x_i^2 * h(x_i) - \bar{x}^2 = \sum_{i=1}^{k} x_i^2 * f(x_i) - \bar{x}^2$$

Beispiel: Berechnung des arithmetischen Mittels und der Varianz
Körpergröße in cm gemessen bei 15 Personen

x_i	$h(x_i)$	$f(x_i)$
150	1	0,067
162	4	0,267
166	3	0,2
168	3	0,2
175	4	0,267
Summe	**15**	**1**

$$\bar{x} = \frac{1}{15} * \sum_{i=1}^{5} x_i * h(x_i) = \frac{1}{15} * (150 + 162 * 4 + 166 * 3 + 168 * 3 + 175 * 4) = 166{,}67 \text{ cm}$$

oder

$$\bar{x} = \sum_{i=1}^{5} x_i * f(x_i) = 150 * \frac{1}{15} + 162 * \frac{4}{15} + 166 * \frac{3}{15} + 168 * \frac{3}{15} + 175 * \frac{4}{15} = 166{,}67 \text{ cm}$$

$$var(X) = (150 - 166{,}67)^2 * 0{,}067 + (162 - 166{,}67)^2 * 0{,}267 + (166 - 166{,}67)^2 * 0{,}2$$
$$+(168 - 166{,}67)^2 * 0{,}2 + (175 - 166{,}67)^2 * 0{,}267 = 43{,}29\ (cm^2)$$

oder:

$$var(X) = (150^2 * 0{,}067 + 162^2 * 0{,}267 + 166^2 * 0{,}2 + 168^2 * 0{,}2 + 175^2 * 0{,}267) - 166{,}67^2 = 43{,}29 \quad (in\ cm^2)$$

Definition:
Gegeben seien $x_1, \dots, x_n$ Realisierungen. Dann heißt

$$s = \sqrt{\frac{1}{n} * \sum_{i=1}^{n} (x_i - \bar{x})^2}$$

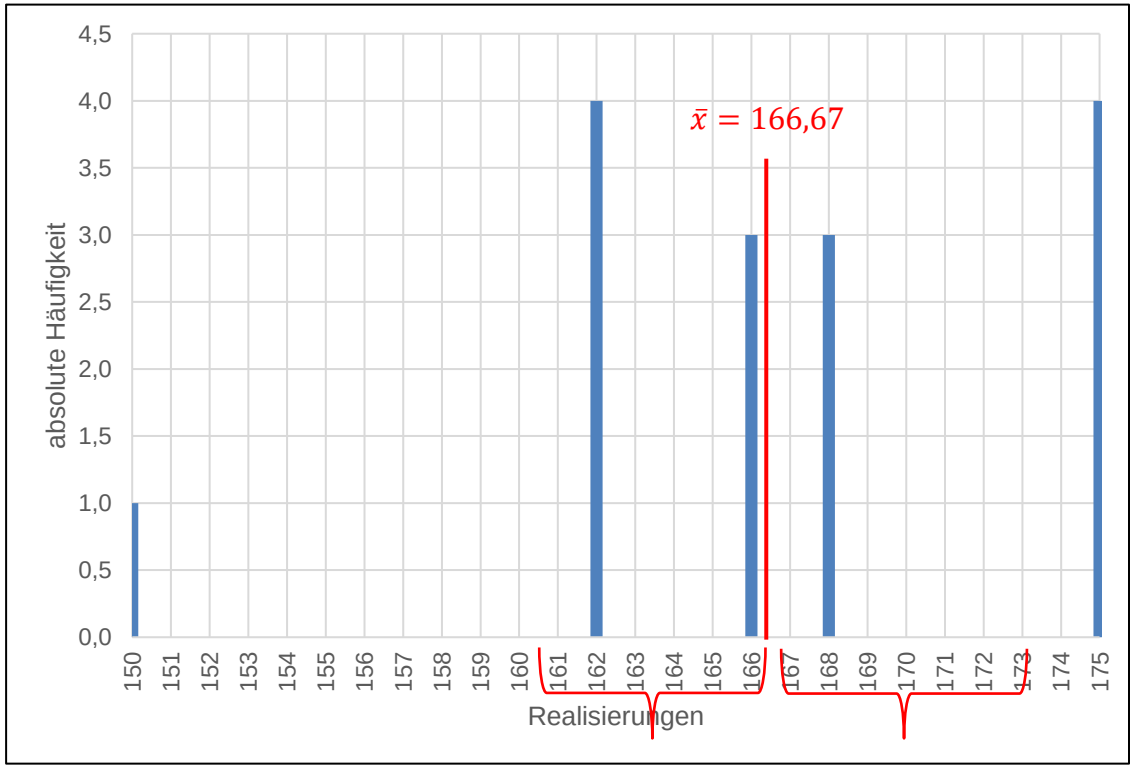
die Standardabweichung. (Sie ist immer positiv.)

Beispiel:
Die Standardabweichung beträgt

$$s = \sqrt{43{,}29\ cm^2} = 6{,}58\ \text{cm}$$

Bemerkung:
Um die die Varianz optisch darzustellen,
wird gerechnet:
arithmetisches Mittel – Standardabweichung
arithmetisches Mittel + Standardabweichung

Innerhalb dieser beiden Bereiche zusammen liegen ca. 68% der Daten (wg. Normalverteilung).



$166{,}67 - 6{,}58 = 160{,}09\ cm$ $166{,}67 + 6{,}58 = 173{,}25\ cm$

Lineare Transformation des arithmetischen Mittel

Sei $\bar{x}$ arithmetisches Mittel einer Verteilung.
Sei $Y = a * X + b$ mit $y_i = a * x_i + b$ eine lineare Transformation der x-Realisierungen.
Dann lautet das arithmetische Mittel der Y-Verteilung $\bar{y} = a * \bar{x} + b$

Lineare Transformation der Varianz

1. Verschiebung:

Addiert man zu einer Verteilung X eine reelle Konstante a, so verschiebt sich die gesamte Verteilung nach rechts für $a > 0$ oder nach links für $a < 0$. Die Varianz ändert sich dabei nicht:

$$var(X + a) = var(X)$$

2. Streckung:

Wird eine Zufallsvariable mit einer rellen Konstanten a multipliziert, wird die Zufallsvariable gestreckt für $a > 0$ oder gestaucht für $a < 0$. Die Varianz berechnet sich wie folgt:

$$var(a * X) = a^2 * var(X)$$

3. Lineare Transformation (Verschiebung und Streckung)

$$var(a * X + b) = a^2 * var(X)$$

Beispiel

Ein Unternehmer hat drei Angestellte, die monatlich 1.500 €, 2.000 € bzw. 2.200 € verdienen. Alle erhalten eine Einmalzahlung von 100 € und eine 3-prozentige Lohnerhöhung. Wie hoch ist die Varianz nach der Lohnerhöhung?

Altes Gehalt	Neues Gehalt
1.500 €	$1.500 * 1{,}03 + 100 = 1.645$ €
2.000 €	$2.000 * 1{,}03 + 100 = 2.160$ €
2.200 €	$2.200 * 1{,}03 + 100 = 2.366$ €
Arithmetisches Mittel $\bar{x} = 1.900$ €	Lineare Transformation des arithmetischen Mittels $Y = 1{,}03 * X + 100$ $\bar{y} = 1.900 * 1{,}03 + 100 = 2.057$ €
Varianz $var(X) = 86.666{,}67$ €^{2}	Lineare Transformation der Varianz $var(Y) = var(1{,}03 * X + 100)$ $= var(1{,}03 * X)$ $= 1{,}03^2 * var(X)$ $= 1{,}03^2 * 86.666{,}67$ €$^2 = 91.944{,}67$ €^{2}
Standardabweichung $s = 294{,}39$ €	Standardabweichung $s = 303{,}22$ €

p-Quantile

Definition:
Gegeben seien n geordnete Realisierungen mit $x_1 \leq x_2 \leq \ ... \leq x_n$. Jeder Wert p mit $0 < p < 1$, für den mindestens ein Anteil p der Daten kleiner oder gleich x_p und mindestens ein Anteil $1 - p$ größer oder gleich x_p ist, heißt p-Quantil:

$$x_p = \begin{cases} x_{\lceil np \rceil} & \text{,wenn np nicht ganzzahlig ist} \\ \dfrac{x_{np} + x_{(np+1)}}{2} & \text{, wenn np ganzzahlig ist} \end{cases}$$

Beispiel:

x_i	$f(x_i)$
1	30
2	40
3	60
4	70
5	60
Summe	260

Berechnung des Medians:

$$n * p = 260 * 0{,}5 = 130 \implies x_{0,5} = \frac{x_{130} + x_{131}}{2} = \frac{3+4}{2} = 3{,}5$$

Berechnung des 95%-Quantils:

$$n * p = 260 * 0{,}95 = 247 \implies x_{0,5} = \frac{x_{247} + x_{248}}{2} = \frac{5+5}{2} = 5$$